

mixup 理论：从邻近风险最小化

到 MIMIC-III 多模态主动学习任务的应用与可视化

MIMIC-III 主动学习项目组

2026 年 8 月

摘要

本文整理 mixup 方法 [Zhang et al.(2018)] 的数学基础, 并给出其在 MIMIC-III 多模态诊断任务 (ModiMix 方法) 中的具体实现与可视化方案。第一节回顾邻近风险最小化 (VRM) 框架并给出 mixup 邻近分布的严格定义; 第二节推导当前项目在连续多模态表示空间中的 mixup 目标; 第三节对比原有的融合特征空间 mixup 与新的模态空间 mixup; 第四节讨论原始论文中 GAN 示意图可否迁移; 第五节到第九节给出五类可视化方案及一个组合图设计; 第十节说明为支持这些可视化需要在实验中保存的诊断产物; 第十一节结合当前主动学习预算结果给出解释框架。

目录

1	原始论文的数学对象	3
1.1	期望风险与经验风险最小化	3
1.2	邻近风险最小化	3
1.3	mixup 邻近分布	3
1.4	mixup 在做什么: 线性行为的归纳偏置	4
1.5	mixup 对 GAN 的稳定化	4
2	当前 MIMIC-III 任务中 ModiMix 的数学实现	4
2.1	为什么不在原始输入空间插值	4
2.2	模态编码与同步插值	5
3	ModiMix 与原始 mixup 的关系	5
3.1	原有的融合特征空间 mixup	5
3.2	ModiMix 的模态空间 mixup	6
4	关于 GAN 示意图的迁移讨论	6
5	可视化方案一: 真实点、插值点与路径	6
5.1	做法	6
5.2	图形设计	7
5.3	对照要求	7

6 可视化方案二：预测插值曲线	7
6.1 标签选择	8
6.2 汇总指标	8
7 可视化方案三：预测与梯度稳定性	8
8 可视化方案四：不确定性曲线	8
9 可视化方案五：虚拟样本对稀缺区域的覆盖	9
9.1 近邻距离	9
9.2 局部密度	9
9.3 凸组合覆盖	9
10 组合图设计	10
11 实验需要补充的诊断产物	10
12 对当前实验结果的解释框架	11
13 结论	11

1 原始论文的数学对象

1.1 期望风险与经验风险最小化

监督学习的目标是寻找函数 $f \in \mathcal{F}$ 描述随机特征向量 X 与随机目标向量 Y 之间的关系，二者服从联合分布 $P(X, Y)$ 。定义损失函数 ℓ 惩罚预测 $f(x)$ 与真实目标 y 的差异，则期望风险为

$$R(f) = \mathbb{E}_{(x,y) \sim P} [\ell(f(x), y)]. \quad (1)$$

实际中分布 P 未知，只能用训练集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ 上的经验分布 P_δ 近似，其中 P_δ 为狄拉克测度的混合：

$$P_\delta(x, y) = \frac{1}{n} \sum_{i=1}^n \delta(x = x_i, y = y_i). \quad (2)$$

最小化 P_δ 下的平均损失即经验风险最小化 (ERM)：

$$R_\delta(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i). \quad (3)$$

1.2 邻近风险最小化

ERM 的朴素经验分布只是逼近真实分布 P 的众多选择之一。邻近风险最小化 (Vicinal Risk Minimization, VRM) [Chapelle et al.(2000)] 用邻近分布逼近 P ：

$$P_\nu(\tilde{x}, \tilde{y}) = \frac{1}{n} \sum_{i=1}^n \nu(\tilde{x}, \tilde{y} \mid x_i, y_i), \quad (4)$$

其中 ν 衡量在训练特征-目标对 (x_i, y_i) 的邻近找到虚拟特征-目标对 $(\tilde{x}, \tilde{y})$ 的概率。例如高斯邻近 $\nu(\tilde{x}, \tilde{y} \mid x_i, y_i) = \mathcal{N}(\tilde{x} - x_i, \sigma^2) \delta(\tilde{y} = y_i)$ 等价于加性高斯噪声增强。对邻近分布采样构造数据集 $\mathcal{D}_\nu = \{(\tilde{x}_i, \tilde{y}_i)\}_{i=1}^m$ ，最小化经验邻近风险：

$$R_\nu(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(\tilde{x}_i), \tilde{y}_i). \quad (5)$$

1.3 mixup 邻近分布

mixup 提出一种通用的邻近分布 [Zhang et al.(2018)]：

$$\mu(\tilde{x}, \tilde{y} \mid x_i, y_i) = \frac{1}{n} \sum_j \mathbb{E}_\lambda \left[\delta(\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \tilde{y} = \lambda y_i + (1 - \lambda)y_j) \right], \quad (6)$$

其中 $\lambda \sim \text{Beta}(\alpha, \alpha)$, $\alpha \in (0, \infty)$ 。简言之，从 mixup 邻近分布采样产生虚拟特征-目标向量

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j, \quad (7)$$

其中 (x_i, y_i) 与 (x_j, y_j) 是从训练数据中随机抽取的两个特征-目标向量, $\lambda \in [0, 1]$ 。超参数 α 控制插值强度: 当 $\alpha \rightarrow 0$ 时 λ 集中于 $\{0, 1\}$, mixup 退化为 ERM。

定义 1.1 (mixup 目标). mixup 训练最小化经验邻近风险

$$\min_f \mathbb{E}_{i,j,\lambda} \left[\ell(f(\lambda x_i + (1-\lambda)x_j), \lambda y_i + (1-\lambda)y_j) \right]. \quad (8)$$

1.4 mixup 在做什么: 线性行为的归纳偏置

mixup 邻近分布可理解为一种数据增强形式, 它鼓励模型 f 在训练示例之间表现出线性行为。这种线性行为减少了在训练示例之外进行预测时的不良振荡; 从奥卡姆剃刀的角度看, 线性也是最简单的可能行为之一, 是一种良好的归纳偏置。

更严格地说, mixup 的先验要求虚拟样本的预测逼近插值标签:

$$f(\lambda x_i + (1-\lambda)x_j) \approx \lambda y_i + (1-\lambda)y_j, \quad (9)$$

即监督信号要求 $f(\tilde{x}) \approx \tilde{y}$ 。原文图 1 展示的是: mixup 带来类别之间线性过渡的决策边界, 提供更平滑的不确定性估计; 图 2 展示的是: 在随机采样的训练样本对之间评估时, mixup 训练的模型在预测与梯度范数两方面都更加稳定。具体而言, 图 2 度量了两个量:

1. 在 $x = \lambda x_i + (1-\lambda)x_j$ 处的预测误差——若预测不属于 $\{y_i, y_j\}$, 计为一次“失误”(miss);
2. 在训练样本之间评估的模型输入梯度范数。

1.5 mixup 对 GAN 的稳定化

mixup 的另一个应用是稳定生成对抗网络 (GAN) [Goodfellow et al.(2014)] 的训练。标准 GAN 求解

$$\max_g \min_d \mathbb{E}_{x,z} [\ell(d(x), 1) + \ell(d(g(z)), 0)], \quad (10)$$

其中 g 把噪声 $z \sim Q$ 映射为伪样本, d 竞争区分真实样本与伪样本。判别器经常给生成器带来消失梯度, 而 mixup 对判别器的梯度起正则化作用, 保证生成器获得稳定的梯度来源。mixup 形式的 GAN 为

$$\max_g \min_d \mathbb{E}_{x,z,\lambda} [\ell(d(\lambda x + (1-\lambda)g(z)), \lambda)]. \quad (11)$$

即判别器的输入在真实样本与生成样本之间插值, 目标标签变为标量 λ 。其目的不是普通分类, 而是让判别器在真实样本与生成样本之间提供更平滑、更稳定的梯度。

2 当前 MIMIC-III 任务中 ModiMix 的数学实现

2.1 为什么不在原始输入空间插值

ModiMix 没有直接混合原始输入 x : 临床文本以离散的 BERT token 序列 (`input_ids`、`token_type_ids`、`attention_mask`) 进入模型, 对离散 token ID 做数值插值没有语义。因此 mixup 在连续表示空间中进行。

2.2 模态编码与同步插值

当前模型先把一个 ICU stay 编码成三个连续表示：

$$h_i = (h_i^{\text{text}}, h_i^{\text{series}}, h_i^{\text{static}}), \quad (12)$$

其中 h_i^{text} 为 ClinicalBERT 池化表示, h_i^{series} 为时序投影与 Transformer 编码输出, h_i^{static} 为静态特征编码输出。对两个样本 i, j 采样 $\lambda \sim \text{Beta}(\alpha, \alpha)$ 后, 三个模态同步插值：

$$\tilde{h}^{\text{text}} = \lambda h_i^{\text{text}} + (1 - \lambda) h_j^{\text{text}}, \quad (13)$$

$$\tilde{h}^{\text{series}} = \lambda h_i^{\text{series}} + (1 - \lambda) h_j^{\text{series}}, \quad (14)$$

$$\tilde{h}^{\text{static}} = \lambda h_i^{\text{static}} + (1 - \lambda) h_j^{\text{static}}. \quad (15)$$

三个模态必须使用同一对样本与同一个 λ , 避免出现“文本来自一组、时序来自另一组”的不一致虚拟样本。标签为 915 维 ICD-9 multi-hot 向量 $y_i, y_j \in \{0, 1\}^{915}$, 混合标签为

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j, \quad (16)$$

混合后的连续表示重新经过 Yang-Wu 门控融合与线性分类头：

$$\tilde{z} = G(\tilde{h}^{\text{text}}, \tilde{h}^{\text{series}}, \tilde{h}^{\text{static}}), \quad \tilde{p} = \sigma(W\tilde{z} + b). \quad (17)$$

训练损失为

$$\mathcal{L} = \mathcal{L}_{\text{clean}} + \gamma \cdot \text{BCEWithLogits}(\tilde{p}, \tilde{y}), \quad (18)$$

其中 γ 为 mixup 权重。当前配置为 $\alpha = 1.0$ 、 $\gamma = 1.0$ 、随机配对、全 batch 参与且不强制 anchor 占主导, 因此 $\lambda \sim \text{Beta}(1, 1)$ 即 $[0, 1]$ 上的均匀分布。这属于连续隐空间 (manifold) mixup, 而非原始输入空间 mixup。整体目标可写成

$$f_{\theta}(G(\lambda h_i + (1 - \lambda) h_j)) \approx \lambda y_i + (1 - \lambda) y_j, \quad (19)$$

其中 h_i 不是单个向量, 而是三个同步插值的模态表示。

3 ModiMix 与原始 mixup 的关系

当前实现存在两条 mixup 路径。

3.1 原有的融合特征空间 mixup

Random+Mixup 与 CoMAL+Mixup 使用旧路径：先由完整模型得到融合特征 $z_i = G(h_i)$ 、 $z_j = G(h_j)$, 再插值

$$\tilde{z} = \lambda z_i + (1 - \lambda) z_j, \quad (20)$$

随后 $\tilde{p} = \sigma(W\tilde{z} + b)$ 。由于分类头是线性的，

$$W\tilde{z} + b = \lambda(Wz_i + b) + (1 - \lambda)(Wz_j + b), \quad (21)$$

该分支约束的是融合后的表示与线性分类头，不直接对多模态融合函数本身提出线性要求。

3.2 ModiMix 的模态空间 mixup

ModiMix 采用

$$\tilde{z} = G(\lambda h_i + (1 - \lambda)h_j). \quad (22)$$

由于 Yang-Wu 门控是非线性的，通常

$$G(\lambda h_i + (1 - \lambda)h_j) \neq \lambda G(h_i) + (1 - \lambda)G(h_j). \quad (23)$$

因此模态空间 mixup 要求整个多模态融合函数在连续模态表示之间保持平滑，而不只是要求线性分类头对插值后的融合特征给出合理预测。这是 ModiMix 与旧路径的本质区别。

4 关于 GAN 示意图的迁移讨论

原始论文图 5 展示 mixup 在建模玩具数据集时稳定 GAN 训练的效果：生成样本（橙色）逐步向真实样本（蓝色）聚集，判别器提供平滑梯度。该图不能直接迁移到当前任务，因为当前实验没有生成器、判别器、隐空间噪声与真实-生成的对抗优化。

但可以借鉴其表达方式，绘制 ModiMix 的多模态版本(图 1): 两个真实 ICU stay 是“标定”，mixup 在它们的连续表示之间生成虚拟点，虚拟点的目标不是硬标签而是两个诊断向量的凸组合，模型需要在这条路径上给出平滑的诊断概率。图题建议为“ModiMix constructs synchronized multimodal vicinal samples between labeled ICU stays”，而不应表述为 GAN 或生成真实患者。

5 可视化方案一：真实点、插值点与路径

5.1 做法

对当前某一轮的已标注池：

1. 收集每个 ICU stay 的融合表示 z_i ，或拼接后的多模态表示 $h_i = [h_i^{\text{text}}; h_i^{\text{series}}; h_i^{\text{static}}]$;
2. 用 PCA 降至二维；
3. 随机选取若干真实样本对 (i, j) ；
4. 对每对样本在 $\lambda \in \{0, 0.1, \dots, 1\}$ 网络上计算

$$\tilde{h}_\lambda = \lambda h_i + (1 - \lambda)h_j; \quad (24)$$

5. 将真实点、虚拟点与连接线段画在同一坐标平面。




图 1: ModiMix 虚拟样本构造流程：两个真实 ICU stay 的多模态表示按同一 λ 同步插值，重新经过融合门控得到预测，监督目标为软标签。

5.2 图形设计

真实已标注 stay 用大圆点，mixup 虚拟点用小圆点， λ 从 0 到 1 用颜色或点大小渐变表示，真实点之间画连接线段。颜色按以下维度之一着色：诊断基数 (cardinality)、某个选定的 ICD-9 标签、主导诊断组、获取轮次。不建议把 915 个标签画成 915 种颜色；更适合选择正标签数最多的若干 ICD-9 类别、一个临床主题、标签基数或 PCA 后的标签嵌入。

PCA 与 UMAP 建议同时使用但解释不同：PCA 适合展示“线性插值”的几何关系；UMAP 适合展示局部聚类，但其投影本身是非线性变换，不能严格说明投影空间中的线段对应原空间线段。正文建议用 PCA，附录可放 UMAP。

5.3 对照要求

必须同时绘制 ERM/plain Random、原有融合特征 mixup 与 ModiMix 三种模型，并使用相同的一组样本对与相同的 λ 网格，否则视觉比较会混入采样差异。

6 可视化方案二：预测插值曲线

对一对真实 ICU stay (i, j) ，在 $\lambda = 0, 0.05, 0.10, \dots, 1$ 网格上计算

$$p_{\theta}(\lambda) = f_{\theta}(\lambda h_i + (1 - \lambda)h_j), \quad (25)$$

同时构造目标曲线

$$y_{\text{target}}(\lambda) = \lambda y_i + (1 - \lambda)y_j. \quad (26)$$

对一个标签 c ，横轴为 λ ，实线为模型预测 $p_{\theta,c}(\lambda)$ ，虚线为目标插值 $y_{\text{target},c}(\lambda)$ ，两端标注真实样本 A 与 B。理想情况下预测曲线平滑地跟随目标曲线。

6.1 标签选择

对 915 个标签不全部绘制，选择： $y_{i,c} \neq y_{j,c}$ 的标签、A 与 B 差异最大的标签、训练集中频率较高的标签、一个仅在 A 出现的标签、一个仅在 B 出现的标签、一个 A 与 B 共有的标签。这样可展示：A 独有诊断概率从高到低平滑变化，B 独有诊断概率从低到高平滑变化，共有诊断全程保持高概率。

6.2 汇总指标

对一批样本对与多个 λ ，计算插值目标误差

$$E_{\text{target}}(\lambda) = \frac{1}{|C|} \left\| p_{\theta}(\lambda) - [\lambda y_i + (1 - \lambda) y_j] \right\|_1, \quad (27)$$

或插值目标 BCE

$$E_{\text{BCE}}(\lambda) = \text{BCE}(p_{\theta}(\lambda), \lambda y_i + (1 - \lambda) y_j). \quad (28)$$

比较 ERM、融合特征 mixup 与 ModiMix 三者的曲线。这直接回答：ModiMix 是否真的学会了“输入表示插值对应标签插值”，而不仅是提升最终 Recall@30。

7 可视化方案三：预测与梯度稳定性

原始论文图 2 的核心度量是插值路径上的预测错误与输入梯度范数。MIMIC 没有连续的原始文本输入，因此梯度定义在连续编码表示上。对插值表示 $\tilde{h}_{\lambda} = \lambda h_i + (1 - \lambda) h_j$ ，计算

$$g(\lambda) = \left\| \frac{\partial \mathcal{L}(\tilde{h}_{\lambda}, \tilde{y}_{\lambda})}{\partial \tilde{h}_{\lambda}} \right\|_2, \quad (29)$$

并分别计算各模态分量

$$g_{\text{text}}(\lambda) = \left\| \frac{\partial \mathcal{L}}{\partial \tilde{h}_{\text{text}}} \right\|_2, \quad g_{\text{series}}(\lambda) = \left\| \frac{\partial \mathcal{L}}{\partial \tilde{h}_{\text{series}}} \right\|_2, \quad g_{\text{static}}(\lambda) = \left\| \frac{\partial \mathcal{L}}{\partial \tilde{h}_{\text{static}}} \right\|_2. \quad (30)$$

绘制时横轴为 λ ，纵轴为梯度范数，实线为 ERM，虚线为 ModiMix，阴影为不同样本对的 95% 区间。若 ModiMix 起作用，预期梯度曲线更少尖峰、中间区域的最大梯度更低、曲线在 $\lambda = 0.5$ 附近更稳定。注意表述应限定为“ModiMix produces smoother optimization geometry along labeled-pair interpolation paths”，不宜直接声称模型更鲁棒。

8 可视化方案四：不确定性曲线

mixup 带来更平滑的不确定性估计。多标签任务中定义每标签 Bernoulli 熵

$$H(p) = -p \log p - (1 - p) \log(1 - p), \quad (31)$$

对一条插值路径计算平均预测熵

$$H_\lambda = \frac{1}{915} \sum_{c=1}^{915} H(p_c(\lambda)). \quad (32)$$

更推荐同时绘制两类曲线：

1. **预测熵曲线**：观察不确定性是否随 A 到 B 的过渡自然增加；
2. **MC dropout 方差**：推理时保留 dropout，重复预测 K 次，

$$U(\lambda) = \frac{1}{915} \sum_{c=1}^{915} \text{Var}_k[p_{\theta,k,c}(\lambda)]. \quad (33)$$

比较 ERM 与 ModiMix：ERM 可能在中间区域出现异常尖峰，ModiMix 理想情况下更平滑；但不应期待不确定性一定单调，因为多标签诊断之间存在复杂结构。

9 可视化方案五：虚拟样本对稀缺区域的覆盖

主动学习场景中，低预算时不仅决策边界不平滑，真实已标注样本本身也很少。因此需要可视化 mixup 虚拟样本是否真正覆盖稀缺区域。

9.1 近邻距离

对每个 mixup 虚拟点，计算其到当前已标注池的最近邻距离

$$d_{\text{NN}}(\tilde{h}) = \min_{k \in L} \|\tilde{h} - h_k\|_2, \quad (34)$$

分别绘制已标注真实点、mixup 虚拟点与候选池点的距离分布，说明虚拟点主要是填充真实样本之间的空隙，还是停留在真实样本附近。

9.2 局部密度

在 PCA 或原始隐空间中用 kNN 估计密度

$$\rho(x) = \frac{k}{d_k(x)^D}, \quad (35)$$

比较已标注真实、mixup 虚拟与未标注候选三类点的密度分布。

9.3 凸组合覆盖

计算每个候选样本到某个已标注样本对线段的距离

$$d_{\text{segment}}(u; h_i, h_j) = \min_{\lambda \in [0,1]} \|u - (\lambda h_i + (1 - \lambda) h_j)\|_2, \quad (36)$$

再对候选池中的每个样本取最小

$$d_{\text{pair}}(u) = \min_{i,j \in L} d_{\text{segment}}(u; h_i, h_j). \quad (37)$$

该指标非常适合主动学习预算曲线：预算 5% 时已标注点少、线段覆盖低；预算 10% 时 mixup 虚拟点填充更多区域；预算 20% 时真实标注覆盖已提高，mixup 的边际作用下降。

10 组合图设计

建议最终组合为一个 2×3 的 figure。

第一行（几何结构）：

- (a) 隐空间 PCA 图：真实已标注 ICU stay、未标注候选、mixup 虚拟点与样本对连线；
- (b) 标签基数/标签嵌入图：点颜色表示诊断数量，展示虚拟标签是否落在 A 与 B 之间；
- (c) 虚拟样本覆盖图：已标注、mixup 与候选三类的最近邻距离或密度。

第二行（模型行为）：

- (d) 预测插值曲线： $p_{\theta}(\lambda)$ 对 $\tilde{y}(\lambda)$ ；
- (e) 梯度范数曲线： $\|\partial\mathcal{L}/\partial h\|$ ；
- (f) 不确定性曲线：预测熵或 MC dropout 方差。

每个面板都固定：同一主动学习轮次、同一已标注池、同一组样本对、同一 λ 网格、同一模型初始化策略与同一验证/测试协议，并同时比较 ERM/Random、融合特征 mixup 与 ModiMix。这样才能把 mixup 的作用与主动学习选样本的作用分离开。

11 实验需要补充的诊断产物

当前训练时 mixup 虚拟样本生成后立即用于损失计算并被丢弃，训练历史中仅保留以下聚合量：

- mixup_loss；
- mixup_virtual_samples；
- anchor 与混合后的标签基数。

为支持上述可视化，还需要保存样本对索引、每个样本的 λ 、混合前后的隐表示、插值路径上的预测、梯度范数与不确定性。

不建议保存每个训练 batch 的全部虚拟样本（存储量过大），而是在训练后、评估时增加一个固定随机种子的可视化采样器：

1. 从某轮已标注池中固定随机抽取 N 对样本；
2. 保存样本对的 ICU stay ID 与 subject ID；
3. 在 $\lambda = 0, 0.05, \dots, 1$ 网格上重新计算插值；
4. 输出小型诊断产物目录：

```

mixup_diagnostics/
  pairs.json                #          lambda
  interpolation_predictions.npz # [N, K, 915]
  interpolation_targets.npz   # [N, K, 915]
  latent_points.npz         #
  gradient_norms.npz        #
  uncertainty.npz           #          MC dropout
  summary.json

```

其中 `pairs.json` 的每条记录包含样本对的索引、主题标识与插值网格：

- `anchor_index`、`partner_index`：样本对在已标注池中的索引；
- `anchor_subject_id`、`partner_subject_id`：ICU stay 的主题标识；
- `lambda_grid`：插值网格，如 `[0.0, 0.05, 0.1]`。

该采样器不污染训练，也不影响主动学习选择。

12 对当前实验结果的解释框架

当前训练表的观察结果是：5% 预算下 Random 与其余方法几乎打平；7.5% 预算下 MoSAIC 领先；10% 与 15% 预算下 MoDIS 领先；20% 与 25% 预算下 MM-CoMAL 领先。这提示 mixup 的价值很可能不是简单地让某个获取方法在所有预算上取胜，而是：

1. 在低预算时缓解模型对少量已标注 stay 的记忆化；
2. 让模型在已标注 stay 之间的隐空间区域预测更稳定；
3. 但随着预算增加，原型、跨模态对齐或获取覆盖度可能比 mixup 更重要。

因此论文中除最终 Recall@30 曲线外，还应绘制

标签预算 $\rightarrow$ 插值误差, 标签预算 $\rightarrow$ 梯度变化, 标签预算 $\rightarrow$ 不确定性平滑度. (38)

一个可能且更有价值的结果是：ModiMix 不一定在每个预算点取得最高 Recall@30，但它显著降低了低预算下的插值误差、梯度尖峰与预测不稳定性。这比单独增加一条 recall 曲线更能证明其实现了 mixup 论文所述的机制。

13 结论

本文把 mixup 从邻近风险最小化框架下的严格定义，映射到 MIMIC-III 多模态诊断任务中的连续表示空间实现：三个模态表示按同一 λ 同步插值，软标签为两个 multi-hot 诊断向量的凸

组合，插值表示重新经过非线性融合门控。与融合特征空间 mixup 相比，模态空间 mixup 对多模态融合函数本身施加了线性平滑约束。基于论文图 1 与图 2 的度量，本文给出五类可视化方案（几何路径、预测插值曲线、梯度范数、不确定性、覆盖分析）与组合图设计，并明确了支持这些可视化所需的诊断产物。这些可视化将回答一个核心问题：mixup 在主动学习低预算场景中的作用，究竟体现在最终指标，还是体现在训练样本之间的模型行为。

参考文献

- [Zhang et al.(2018)] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. In *International Conference on Learning Representations (ICLR)*, 2018.
- [Chapelle et al.(2000)] Olivier Chapelle, Jason Weston, Léon Bottou, and Vladimir Vapnik. Vicinal risk minimization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2000.
- [Goodfellow et al.(2014)] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2014.